

Ejercicio 3.3

Aprendizaje Supervisado con Google Teachable Machine

ALUMNO Miguel Jericó

FORMACIÓN INAEM · Análisis de Datos e IA

HERRAMIENTA Google Teachable Machine (Standard Image Model)

BLOQUE Redes neuronales y clasificación supervisada de imágenes

01 Acceder a Teachable Machine

Accede a: <https://teachablemachine.withgoogle.com>


Pulsa: **Get Started**

Después: **Image Project**

Y finalmente: **Standard Image Model**

CAPTURA 1

Realiza una captura de la pantalla inicial del proyecto.



02 Elegir las categorías


Vamos a entrenar un modelo para distinguir dos animales. Renombra las clases como:

Clase 1 → **Perro**

Clase 2 → **Gato**

CAPTURA 2

Realiza una captura donde se vean las dos clases creadas.



03 Buscar imágenes

Abre una nueva pestaña y entra en Google Imágenes. Busca:

- Perro
- Gato


Descarga aproximadamente 20 imágenes diferentes de cada categoría. Procura que sean variadas:

- Diferentes razas
- Distintos colores
- Diferentes posiciones
- Distintos fondos
- Distintos tamaños

Guárdalas en dos carpetas: Perro y Gato.

CAPTURA 3

Realiza una captura de las dos carpetas con las imágenes descargadas.




04 Importar las imágenes

En Teachable Machine pulsa: **Upload**

Selecciona todas las imágenes de la carpeta Perro. Después haz lo mismo con la carpeta Gato.

CAPTURA 4

Realiza una captura donde se vean todas las imágenes cargadas en ambas clases.




05 Entrenar el modelo

Pulsa: Train Model

Espera unos segundos mientras la IA aprende.

CAPTURA 5

Realiza una captura mientras el modelo está entrenando.



06 Probar el modelo


Pulsa: Upload Image

Ahora descarga de Google otras imágenes de perros y gatos que no hayas utilizado durante el entrenamiento. Ve probándolas una a una. Observa:

- Categoría predicha
- Porcentaje de confianza

CAPTURA 6

Realiza una captura mostrando una predicción correcta.



07 Buscar errores


Ahora intenta "engañar" al modelo. Prueba imágenes de:

- Lobo
- Zorro
- Cachorro
- Peluche de perro
- Dibujo animado de un gato

Observa qué ocurre.

CAPTURA 7

Realiza una captura de una predicción incorrecta o dudosa.



08 Mejorar el modelo


Descarga 20 imágenes adicionales de cada animal. Ahora intenta que haya más variedad:

- De noche
- De perfil
- Tumbados
- Corriendo
- Con personas
- Varios animales en la misma imagen

Entrena nuevamente el modelo.

CAPTURA 8

Realiza una captura del nuevo entrenamiento.



09 Comparar resultados


Vuelve a probar imágenes nuevas. ¿Ha mejorado la precisión?

RESULTADO

Sí. Al haber incrementado el volumen de muestra en el modelo, la precisión es mayor.

CAPTURA 9

Realiza una captura de una nueva predicción.




10 Crear una tercera categoría

Añade una nueva clase, por ejemplo: **Caballo**

Descarga unas 20 imágenes, entrena otra vez y prueba imágenes nuevas.

CAPTURA 10

Realiza una captura del modelo clasificando correctamente un caballo.



11 Análisis del modelo

Se han probado siete imágenes nuevas frente al modelo ya entrenado con tres clases. La tabla recoge, para cada una, la predicción del modelo, el porcentaje de confianza obtenido y si el resultado ha sido correcto.








Imagen	Captura	Predicción	Probabilidad	¿Ha acertado?
Perro 1		Perro	61,00 %	Sí
Perro 2		Perro	100,00 %	Sí
Gato 1		Gato	100,00 %	Sí
Gato 2		Gato	100,00 %	Sí
Caballo 1		Perro	91,00 %	No

Imagen	Captura	Predicción	Probabilidad	¿Ha acertado?
Lobo		Perro	82,00 %	No (es un lobo; el modelo lo clasifica como perro)
Peluche		Perro	100,00 %	No (objeto inanimado; falso positivo de la clase perro)



Preguntas de reflexión

P1. ¿Qué son los datos etiquetados?

Son conjuntos de datos que han sido clasificados o anotados previamente con la respuesta correcta antes de introducirlos en la red neuronal. En esta práctica, se renombraron las clases manualmente a "Perro" y "Gato", y se crearon carpetas estructuradas con esos mismos nombres para almacenar las fotografías. Esta estructura de directorios y nombres actúa como las etiquetas que enseñan al modelo a qué clase pertenece cada lote de imágenes.

P2. ¿Por qué es importante utilizar muchas imágenes diferentes?

Es vital para garantizar que el modelo generalice correctamente y no memorice el ruido. Por este motivo, el entrenamiento inicial requirió buscar 20 imágenes con diferentes razas, colores, posiciones, tamaños y fondos. Más adelante, para mejorar el sistema, se introdujo aún más varianza añadiendo imágenes de noche, de perfil, corriendo, con personas o con varios animales simultáneamente.

P3. ¿Qué ocurre cuando el modelo intenta clasificar una imagen que nunca ha visto?

El algoritmo carece de contexto real: simplemente calcula distancias matemáticas e intenta encajar la nueva imagen dentro de las categorías que ya domina, basándose en patrones de píxeles compartidos. Al intentar engañar al modelo, se observa que fuerza la clasificación de un lobo o un caballo hacia la clase "Perro", a menudo con altos porcentajes de confianza.

P4. ¿Ha mejorado el modelo después de añadir más imágenes?

Sí, la precisión es mayor al haber incrementado el volumen de la muestra. Al añadir 20 imágenes adicionales por cada clase y abarcar escenarios más complejos, los pesos del modelo se ajustan mejor, haciéndolo más resistente ante imágenes que se alejan del encuadre ideal.

P5. ¿Qué imágenes han producido más errores?

Los errores principales surgieron con las imágenes seleccionadas deliberadamente para engañar al sistema. El caballo, el lobo y el peluche de perro provocaron falsos positivos hacia la categoría "Perro", ya que comparten texturas, formas (hocicos, orejas) o paletas de color presentes en las imágenes de entrenamiento originales.

P6. ¿Crees que este modelo sería suficientemente fiable para utilizarse en una empresa? Justifica tu respuesta.

No sería viable en un entorno empresarial de producción real. Para que fuera viable necesitaría un entrenamiento inmensamente mayor, balanceado y auditado. Este prototipo carece de una clase "Desconocido" o de un umbral de descarte, lo que provoca errores críticos de clasificación, como identificar un objeto inanimado (el peluche) como un perro con total seguridad.

VEREDICTO

El modelo no es apto para producción: falta una clase de rechazo y un proceso de validación más riguroso antes de poder confiar en sus predicciones.

P7. Indica tres aplicaciones reales donde podría utilizarse un sistema similar.

- **Control de calidad en manufactura:** sistemas de visión en líneas de montaje que clasifican productos como "Aptos" o "Defectuosos" a partir de anomalías visuales.
- **Clasificación documental automatizada:** motores OCR y de visión que escanean documentos entrantes y los clasifican al instante como facturas, contratos o currículums.
- **Gestión inteligente de residuos:** cámaras en plantas de reciclaje que identifican y separan plásticos, metales y cartones en la cinta transportadora para automatizar su procesamiento.